Projekt Uczenie Maszynowe

Etap 1: Analiza danych

Mieszkania w Polsce: dane liczbowe (Kaggle)
i dane tekstowe (Hugging Face / Otodom)

Informacja o zespole:

Imię i nazwisko	**ID**	**Zakres pracy w etapie 1**
Kyrylo Biletskyi	71566	EDA zbioru tekstowego, opis źródła i podzbioru
Danylo Kyrylchuk	71747	EDA zbioru liczbowego, opis źródła
Vladyslav Spytskyi	74324	pytania badawcze, testy statystyczne
Mykhailo-Maksym Kit	71517	repozytorium, skład raportu, wysyłka

1. Informacja o danych

W projekcie wykorzystano dwa zbiory o różnych modalnościach, oba dotyczą rynku mieszkań w Polsce. Oba zbiory zawierają dane rzeczywiste, czyli ogłoszenia faktycznie opublikowane w serwisach z ofertami nieruchomości; nie są to dane symulowane ani generowane syntetycznie.

	Zbiór 1 (dane liczbowe)	**Zbiór 2 (dane w języku naturalnym)**
Nazwa	Apartment Prices in Poland	otodom-pl-scraper-polish-real-estate-data-sample-data
Platforma	Kaggle	Hugging Face
Użyty plik	`apartments_pl_2023_08.csv`	`sample.parquet`
Rozmiar	18 905 wierszy × 28 kolumn	100 wierszy × 51 kolumn
Zawartość	oferty sprzedaży mieszkań, sierpień 2023	ogłoszenia z portalu Otodom.pl, wyłącznie z Warszawy, zebrane 15.05.2026
Wykorzystane kolumny	wszystkie; zmienna docelowa: `price` (zł)	`title`, `shortDescription` (tekst po polsku)

Zbiór 1: grupy zmiennych

- Lokalizacja: `city`, `latitude`, `longitude`, `centreDistance`
- Parametry mieszkania: `type`, `squareMeters`, `rooms`, `floor`, `floorCount`, `buildYear`, `buildingMaterial`, `condition`, `ownership`
- Otoczenie (dane z OpenStreetMap): `poiCount` oraz odległości do szkoły, przychodni, poczty, przedszkola, restauracji, uczelni i apteki (`schoolDistance`, `clinicDistance`, `postOfficeDistance`, `kindergartenDistance`, `restaurantDistance`, `collegeDistance`, `pharmacyDistance`)
- Udogodnienia (tak/nie): `hasParkingSpace`, `hasBalcony`, `hasElevator`, `hasSecurity`, `hasStorageRoom`
- Cena ofertowa: `price`

Zbiór 2: struktura

- 36 z 51 kolumn zawiera dane, a 15 kolumn jest w całości puste: `advertType`, `isPrivate`, `market`, `terrainAreaSqm`, `totalFloors`, `district`, `subdistrict`, `postalCode`, `latitude`, `longitude`, `isFeatured`, `hasOpenDay`, `investmentName`, `dateCreatedFirst`, `labels`.
- Poza tekstem zbiór zawiera m.in. `price`, `pricePerSqm`, `areaSqm`, `rooms`, `floor`, `city`, `agencyName`, `dateCreated`, `scrapedAt`.

2. Źródła

Zbiór 1

Tytuł: *Apartment Prices in Poland*, autor: Krzysztof Jamroz

Adres: https://www.kaggle.com/datasets/krzysztofjamroz/apartment-prices-in-poland

Opis autora: oferty sprzedaży i wynajmu mieszkań z 15 największych miast Polski; dane pochodzą z lokalnych serwisów z ogłoszeniami i zostały rozszerzone o odległości do punktów zainteresowań z OpenStreetMap.

Zakres czasowy całego zbioru: sierpień 2023 – czerwiec 2024, migawki miesięczne.

Pliki: apartments_pl_YYYY_MM.csv (oferty sprzedaży), apartments_rent_pl_YYYY_MM.csv (oferty wynajmu).

Licencja: Apache License 2.0 (https://www.apache.org/licenses/LICENSE-2.0), zgodnie z informacją na stronie zbioru.

Zbiór 2

Identyfikator: logiover/otodom-pl-scraper-polish-real-estate-data-sample-data (Hugging Face Datasets)

Adres: https://huggingface.co/datasets/logiover/otodom-pl-scraper-polish-real-estate-data-sample-data

Treść: ogłoszenia z portalu Otodom.pl (największy polski portal nieruchomości, grupa OLX), adresy ogłoszeń w kolumnie detailUrl prowadzą do Otodom.pl.

Schemat kolumn odpowiada danym zwracanym przez narzędzie Otodom.pl Scraper autora Logiover (platforma Apify): https://apify.com/logiover/otodom-pl-scraper-polish-real-estate-data

Licencja: CC BY 4.0 (https://creativecommons.org/licenses/by/4.0/), zgodnie z metadanymi zbioru na Hugging Face. Autor: Logiover.

Data dostępu do obu zbiorów: 28.10.2026.

3. Podzbiory i sposób ich uzyskania

Zbiór 1

Podzbiór: jeden z 11 plików miesięcznych, apartments_pl_2023_08.csv (sierpień 2023), wyłącznie oferty sprzedaży. Plik wykorzystano w całości, bez losowania i filtrowania wierszy.

Jak otrzymać: pobrać zbiór ze strony Kaggle (przycisk *Download*), rozpakować archiwum i skopiować plik apartments_pl_2023_08.csv do folderu data/.

Zbiór 2

Podzbiór: cały dostępny plik sample.parquet (100 ogłoszeń), bez dodatkowego losowania.

Jak otrzymać: pobrać plik sample.parquet ze strony zbioru na Hugging Face (zakładka *Files and versions*) i umieścić w folderze data/.

Struktura folderów i wczytanie danych

```
# data/apartments_pl_2023_08.csv

# data/sample.parquet

import pandas as pd


df_num = pd.read_csv('data/apartments_pl_2023_08.csv')

df_text = pd.read_parquet('data/sample.parquet')  # wymaga pakietu pyarrow
```

4. Analiza eksploracyjna danych (EDA)

4.1. Zbiór 1: jakość danych

Duplikaty: brak (wszystkie id są unikalne).

Brakujące wartości występują w 14 kolumnach:

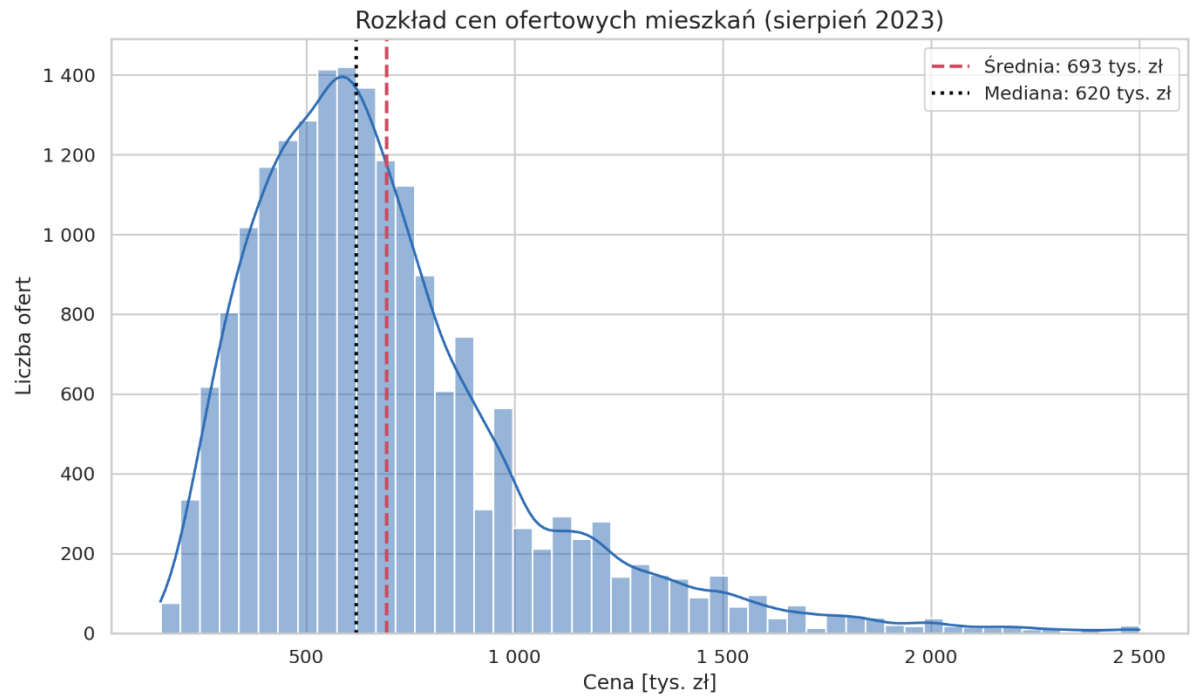
Kolumna	Braki	Udział
condition	14 344	75,9%
buildingMaterial	7 387	39,1%
type	4 039	21,4%
floor	3 438	18,2%
buildYear	3 271	17,3%
hasElevator	926	4,9%
collegeDistance	565	3,0%
floorCount	262	1,4%
pozostałe 6 kolumn (odległości do POI)	każda poniżej 1%	

4.2. Zbiór 1: statystyki opisowe

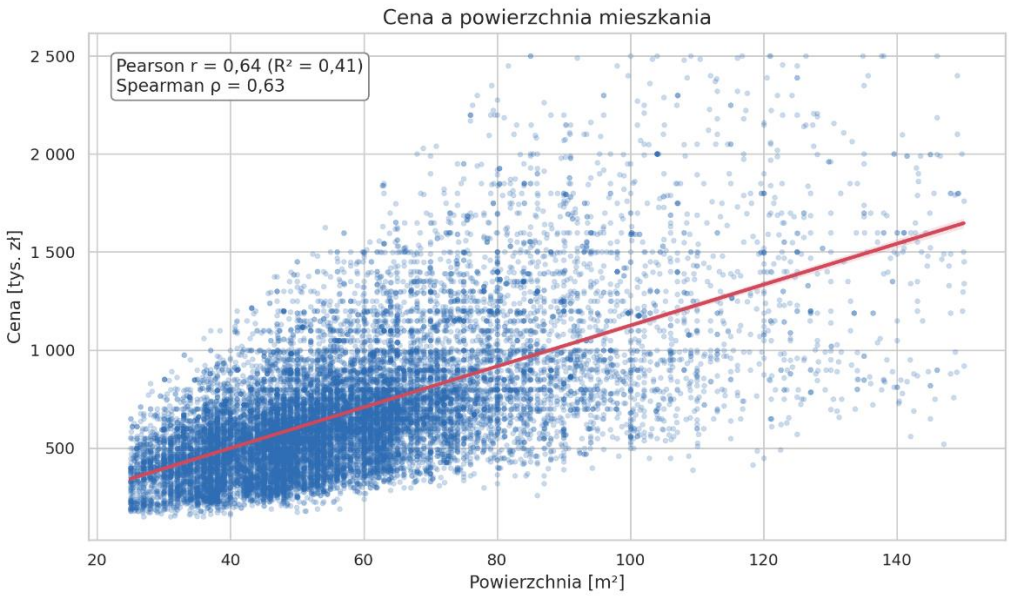
Zmienna	Min	Mediana	Średnia	Maks.
Cena (zł)	150 000	620 000	692 559	2 500 000
Powierzchnia (m²)	25	54,4	58,5	150
Liczba pokoi	1	3	2,68	6
Cena za m² (zł)	3 012	11 383	12 008	29 995

Zakresy ceny (150 tys. – 2,5 mln zł) i powierzchni (25–150 m²) mają wyraźne granice. Wygląda na to, że autor zbioru wcześniej odfiltrował wartości skrajne.

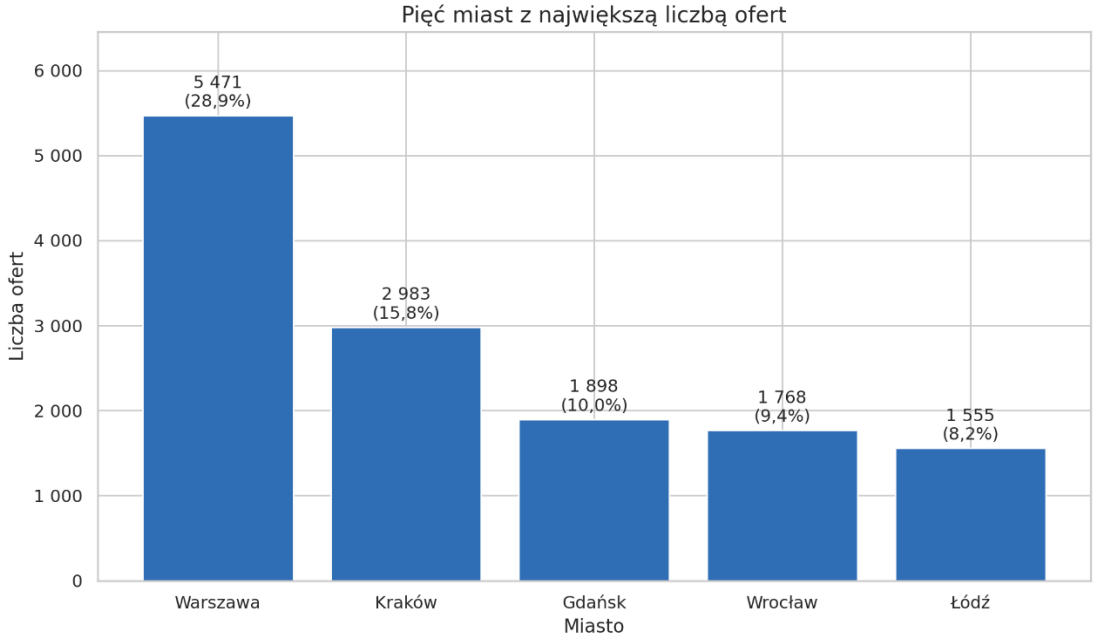
4.3. Wykresy



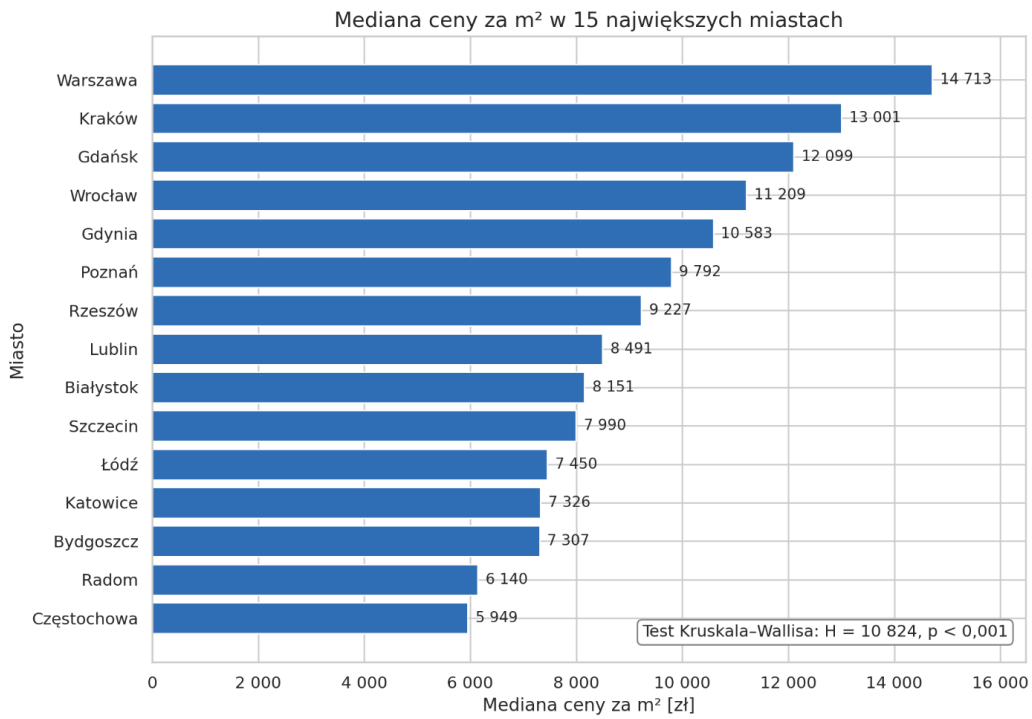
*Wykres: 1. **Rozkład cen**. Rozkład jest prawoskośny (skośność 1,56), średnia (692,6 tys. zł) jest wyższa od mediany (620 tys. zł). W przedziale 400 tys. – 1 mln zł mieści się 68,6% ofert. Powyżej 2 mln zł jest tylko 126 ofert (0,67%), a maksymalna cena to 2,5 mln zł. Po zlogarytmowaniu ceny skośność spada do 0,08, więc rozkład jest zbliżony do log-normalnego.*



*Wykres: 2. **Cena a powierzchnia.** Zależność jest dodatnia i umiarkowanie silna: współczynnik Pearsona r = 0,64 (R² = 0,41), Spearmana ρ = 0,63.*
Rozrzut cen rośnie wraz z metrażem, czyli przy dużych mieszkaniach sama powierzchnia słabiej wyjaśnia cenę.



*Wykres: 3. **Liczba ofert według miast.** Zbiór obejmuje 15 miast. Najwięcej ofert mają: Warszawa (5 471; 28,9%), Kraków (2 983), Gdańsk (1 898), Wrocław (1 768) i Łódź (1 555). Razem te pięć miast daje 72,3% wszystkich ofert.*



Wykres: 4. Mediana ceny za m² we wszystkich 15 miastach, z testem Kruskala–Wallisa. Ten wykres ilustruje tabelę z sekcji 4.4 oraz pytanie badawcze nr 2.

4.4. Zbiór 1: ceny w miastach

Miasto	Liczba ofert	Mediana ceny (zł)	Mediana ceny za m² (zł)
Warszawa	5 471	799 000	14 713
Kraków	2 983	680 000	13 001
Gdańsk	1 898	670 000	12 099
Wrocław	1 768	620 000	11 209
Gdynia	830	599 000	10 583
Poznań	773	545 000	9 792
Rzeszów	194	490 500	9 227
Lublin	691	460 000	8 491
Białystok	262	427 000	8 151
Szczecin	552	480 000	7 990
Łódź	1 555	359 000	7 450
Katowice	488	393 000	7 326
Bydgoszcz	941	374 000	7 307
Radom	324	320 000	6 140
Częstochowa	175	295 000	5 949

Różnice ceny za m² między miastami są istotne statystycznie (test Kruskala–Wallisa: H = 10 824, p < 0,001).

4.5. Zbiór 1: zależności z ceną

Korelacja Pearsona z ceną: powierzchnia 0,64; liczba pokoi 0,49; liczba POI w okolicy 0,18; rok budowy 0,15. Pozostałe zmienne liczbowe mają korelację bliską zera lub słabą ujemną (np. odległość od przychodni −0,12).

Liczba pokoi jest silnie skorelowana z powierzchnią (r = 0,83), więc obie zmienne niosą część tej samej informacji.

Mediana ceny za m² dla mieszkań z windą: 12 978 zł, bez windy: 10 123 zł. Z ochroną: 12 979 zł, bez: 11 155 zł (testy Manna–Whitneya, p < 0,001).

Budynki z lat 2010+: mediana 13 438 zł/m², budynki z lat 1946–1989: 10 588 zł/m².

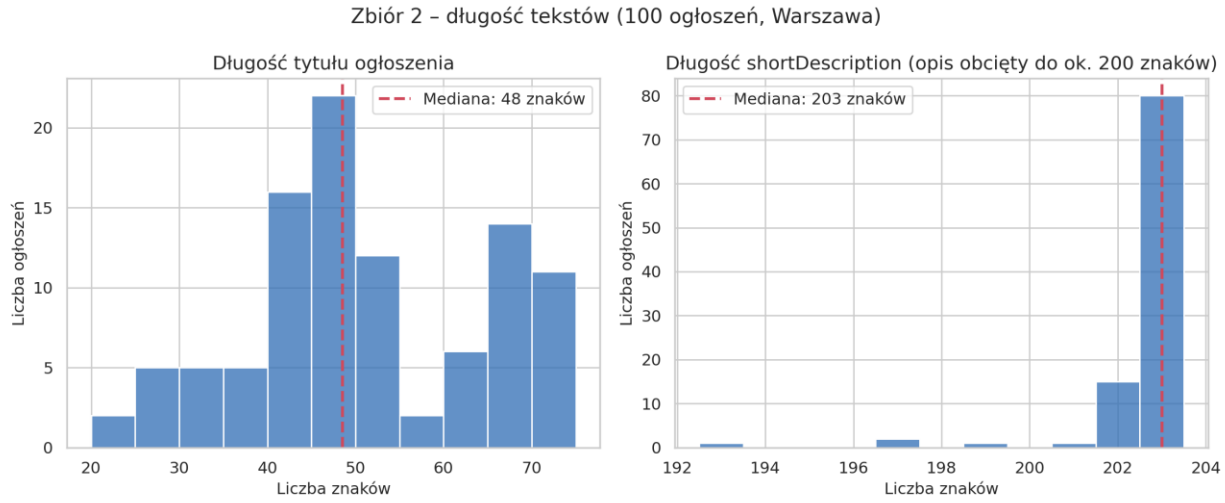
Stan „premium": 12 037 zł/m², „low": 8 906 zł/m². Własność spółdzielcza: 9 667 zł/m², odrębna własność: 11 593 zł/m².

4.6. Zbiór 2: dane tekstowe

Struktura i jakość danych

- Zbiór liczy 100 ogłoszeń sprzedaży mieszkań w Warszawie, zebranych 15.05.2026. Tekst znajduje się w kolumnach `title` (tytuł) i `shortDescription` (skrócony opis); oba pola nie mają braków, język polski.
- `shortDescription` jest obcięty przez serwis do ok. 200 znaków: wszystkie 100 opisów kończy się znakami „...", a ich długość mieści się w przedziale 193–203 znaków. Tytuły mają najwyżej 70 znaków (11 tytułów ma dokładnie 70).
- Cechy strukturalne: 99 ofert w PLN (w tym 2 bez ceny) i 1 oferta w EUR (jej cena za m² jest również w EUR). Dla 97 ofert w PLN z podaną ceną mediana ceny wynosi 823 430 zł, a mediana ceny za m² 17 217 zł (zbiór 1, Warszawa: 14 713 zł).
- Przykładowe tytuły: „Praga Płd | 3 pokoje | Balkon | Wykończone | Dostępne od już | 0% Prowizji"; „10 700 zł /m2 | MIESZKANIE | STARA MIŁOSNA | DWA POZIOMY"; „nowy budynek z recepcją, ładna kawalerka na 4 piętrze z windą".

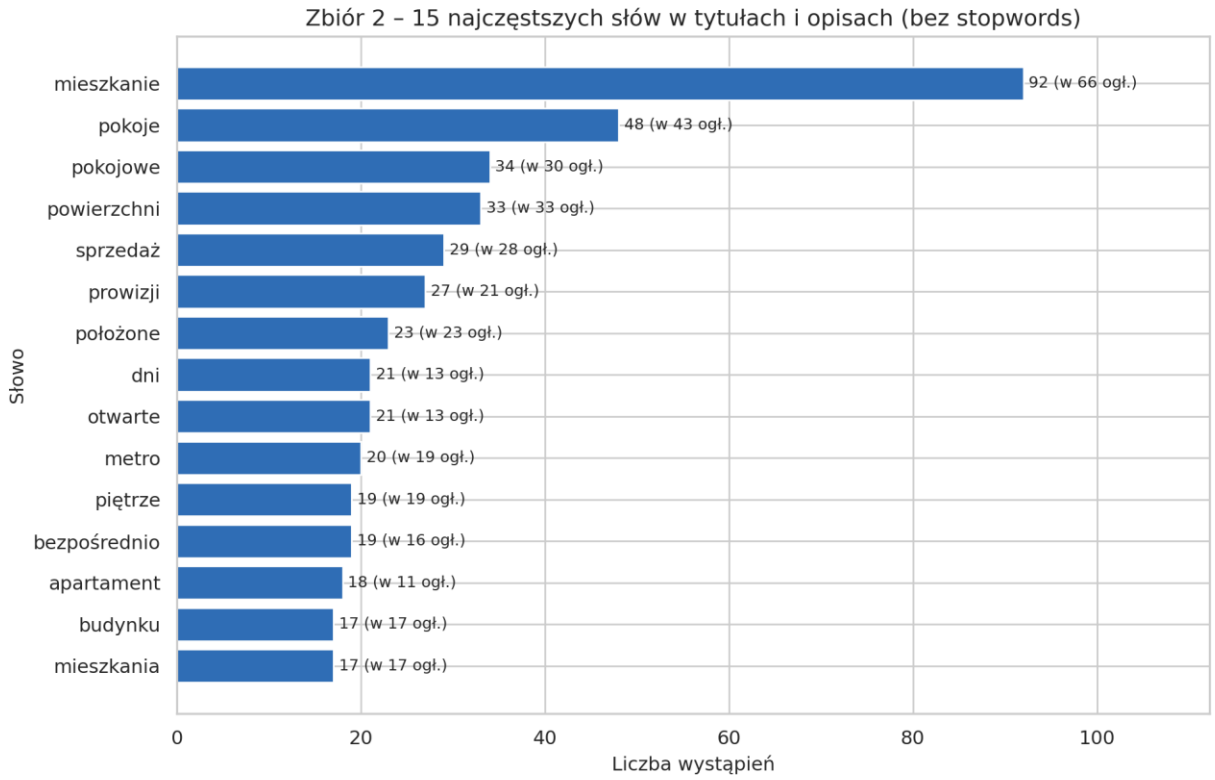
Długość tekstów (wykres 5)



Pole	Miara	Średnia	Mediana	Min	Maks.
`title`	znaki	50,5	48	22	70
`title`	słowa	8,3	8	4	15
`shortDescription`	znaki	202,6	203	193	203
`shortDescription`	słowa	27,6	27	22	34

Długość tytułu jest zróżnicowana (odchylenie standardowe 13,3 znaku), a długość `shortDescription` jest praktycznie stała (odchylenie 1,4 znaku), więc nie niesie informacji o ogłoszeniu. W pytaniu nr 6 długość można więc mierzyć tylko na podstawie `title`.

Najczęstsze słowa (wykres 6)



Tytuły i opisy analizowano łącznie: małe litery, tokeny złożone z liter (min. 3 znaki), bez własnej listy 98 polskich słów funkcyjnych (stopwords), bez lematyzacji (np. „mieszkanie” i „mieszkania” liczone osobno). Po usunięciu stopwords zostało 2 306 słów, w tym 943 różne.

Słowo	Wystąpienia	Ogłoszenia (z 100)
mieszkanie	92	66
pokoje	48	43
pokojowe	34	30
powierzchni	33	33
sprzedaż	29	28
prowizji	27	21
położone	23	23
dni	21	13
otwarte	21	13
metro	20	19
piętrze	19	19
bezpośrednio	19	16
apartament	18	11
budynku	17	17
mieszkania	17	17

Słowo „dni” występuje w 13 ogłoszeniach, z czego 12 pochodzi od dwóch biur sprzedaży nowych mieszkań (8 i 4 ogłoszenia); to powtarzalna fraza „dni otwarte”, a nie cecha oferty. Wzmianki o cechach z pytania nr 7: „balkon” (w dowolnej formie) występuje w 17 ogłoszeniach, „winda” w 6.

Duplikaty i prawie-duplikaty

Rodzaj	Grupy	Ogłoszenia
identyczne `title`	3	6
identyczne `shortDescription`	6	14
ten sam `detailUrl`	1	2
prawie-duplikaty (podobieństwo Jaccarda ≥ 0,8)	8	18

Prawie-duplikaty to ogłoszenia, których zbiory słów w tytule lub opisie pokrywają się w co najmniej 80% (podobieństwo Jaccarda). Po usunięciu nadmiarowych kopii zostaje 90 ogłoszeń (10 nadmiarowych). Tylko jedna grupa to ta sama oferta: ogłoszenie „Praga Płd | 3 pokoje…” występuje pod dwoma identyfikatorami (`adId` 68008698 i 96800869800067) z tym samym `detailUrl`. Pozostałe grupy to szablonowe ogłoszenia różnych lokali tego samego dewelopera lub biura sprzedaży, z różnymi cenami lub liczbą pokoi. Przykład: 6 ogłoszeń z frazą „Hala garażowa” w tytule pochodzi z jednego biura sprzedaży (RYNEK PIERWOTNY BIURO SPRZEDAŻY MIESZKAŃ K.L.), a ich ceny różnią się, np. 679 165 zł i 791 609 zł.

5. Ograniczenia danych

1. Zbiór 1 zawiera ceny ofertowe, a nie transakcyjne, z jednego miesiąca (sierpień 2023) i z 15 największych miast. Ceny (150 tys. – 2,5 mln zł) i powierzchnie (25–150 m²) mają ostre granice, co wskazuje na wcześniejszą filtrację przez autora zbioru.
2. Rozbieżność czasowa: zbiór 2 zebrano 15.05.2026, ok. 33 miesiące (ok. 2,7 roku) po zbiorze 1. Porównanie cen między zbiorami nie uwzględnia zmian cen w tym okresie.
3. Rozbieżność zakresu: zbiór 2 obejmuje wyłącznie Warszawę (100 ofert), a zbiór 1 15 miast. Porównanie jest możliwe tylko dla Warszawy (5 471 ofert w zbiorze 1 wobec 100 w zbiorze 2).
4. Próbka zbioru 2 nie jest losowa: 98 z 99 poprawnych dat utworzenia ogłoszenia (`dateCreated`) przypada na 14–15.05.2026 (84 ogłoszenia z 15.05), więc to wąski wycinek rynku z dwóch dni, a nie reprezentatywny przekrój.
5. Zbiór 2 jest mały (100 ogłoszeń) i zawiera powtórzenia: 8 grup prawie-duplikatów obejmuje 18 ogłoszeń, a po usunięciu nadmiarowych kopii zostaje 90. Wyniki mają charakter orientacyjny.
6. `shortDescription` jest obcięty do ok. 200 znaków (wszystkie 100 opisów), więc słownictwo opisu dotyczy tylko początku ogłoszenia, a jego długość nie niesie informacji.
7. W zbiorze 2 15 z 51 kolumn jest pustych (m.in. `latitude`, `longitude`, `district`, `totalFloors`, `market`), co wyklucza analizę przestrzenną. Ponadto 1 oferta jest w EUR, 2 nie mają ceny, a 1 ma niepoprawną datę utworzenia (29.02.1999).
8. Zbiór 1 ma duże braki w kolumnach `condition` (76%) i `buildingMaterial` (39%).
9. Zbiory nie mają wspólnego klucza, więc nie można ich łączyć wiersz do wiersza. Analizy wspólne porównują rozkłady i efekty (mediany, wzmianki w tekście).

6. Pytania badawcze

Nr	Pytanie badawcze	Zbiór	Metoda
1	Które cechy mieszkania najsilniej wiążą się z ceną ofertową?	1	korelacja Pearsona i Spearmana, macierz korelacji
2	Czy cena za m² różni się istotnie między miastami i które miasta są najdroższe?	1	test Kruskala–Wallisa, statystyki grupowe
3	Czy udogodnienia (winda, ochrona, parking, komórka lokatorska) i wiek budynku wiążą się z wyższą ceną za m²?	1	testy Manna–Whitneya, porównanie median
4	Jak dobrze cenę ofertową można przewidzieć na podstawie cech liczbowych i kategorycznych?	1	regresja (Etap 2)
5	Jakie informacje o mieszkaniu (liczba pokoi, piętro, rok budowy, udogodnienia) zawierają tytuły i opisy ogłoszeń i czy zgadzają się z kolumnami strukturalnymi?	2	analiza tekstu, wyrażenia regularne
6	Czy długość tytułu i słownictwo ogłoszenia (np. „balkon”, „winda”, „0% prowizji”) wiążą się z ceną za m²?	2	statystyki długości tytułu, częstość słów, korelacja Spearmana
7	Czy mediana ceny za m² w ofertach warszawskich ze zbioru 2 (maj 2026) różni się od mediany dla Warszawy ze zbioru 1 (14 713 zł, sierpień 2023) i czy cechy wspomniane w tekście ogłoszeń (balkon, winda) zgadzają się z efektami z testów w sekcji 4.5?	1 i 2	bootstrapowy przedział ufności mediany, test Manna–Whitneya, porównanie median z cechą i bez cechy

Link GitHub

https://github.com/Deltmax-45/Projekt-Uczenie-maszynowe